

**Informe: Transforma texto en embeddings**

**PROCESAMIENTO DE LENGUAJE NATURAL**

**WILSON ALFONSO DÍAZ CAPADOR**

**UNIVERSIDAD DE CUNDINAMARCA  
PROGRAMA ESPECIALIZACIÓN EN INTELIGENCIA ARTIFICIAL  
FACULTAD DE INGENIERÍA  
2026**

# **Del token al vector: laboratorio de transformación de texto en embeddings**

## **Enlaces de evidencia**

Repositorio GitHub (público): <https://github.com/SonicWD/PROCESAMIENTO-DE-LENGUAJE-NATURAL>. Notebook del laboratorio, ya ejecutado en Google Colab con salidas y figuras: [https://colab.research.google.com/github/SonicWD/PROCESAMIENTO-DE-LENGUAJE-](https://colab.research.google.com/github/SonicWD/PROCESAMIENTO-DE-LENGUAJE-NATURAL/blob/main/REA1_Embeddings/Laboratorio_Transforma_Texto_Embeddings.ipynb)

[NATURAL/blob/main/REA1\\_Embeddings/Laboratorio\\_Transforma\\_Texto\\_Embeddings.ipynb](https://colab.research.google.com/github/SonicWD/PROCESAMIENTO-DE-LENGUAJE-NATURAL/blob/main/REA1_Embeddings/Laboratorio_Transforma_Texto_Embeddings.ipynb).

Las imágenes de este informe se extraen de esas celdas (mapas de calor y PCA). La semilla es 42; el corpus son las ocho oraciones del cuaderno.

## **1. Introducción y objetivo**

Los modelos de aprendizaje automático no leen palabras: leen números. Transformar texto en embeddings consiste en mapear oraciones a vectores de números reales de modo que la geometría del espacio —distancias y ángulos— refleje semántica (Mikolov et al., 2013; Jurafsky y Martin, 2023). Este informe documenta el laboratorio del REA 1: se parte de un corpus propio en español con tres temas (NLP, vivienda y deporte), se construyen representaciones dispersas (one-hot y TF-IDF) y densas (LSA; PPMI + SVD) y se evalúa si el espacio sirve para comparar documentos y recuperar avisos con una consulta nueva.

## **2. Marco técnico: el proceso de embedding**

El flujo tiene cinco etapas. Primera, normalización: minúsculas, retiro de puntuación y stopwords del español, para no gastar dimensiones en artículos. Segunda, tokenización por

espacios sobre el texto ya limpio. Tercera, vectorización. En one-hot y TF-IDF cada eje es un término del vocabulario; el laboratorio obtuvo  $|V| = 57$  dimensiones. TF-IDF baja el peso de palabras muy comunes en el corpus y sube el de las distintivas (Salton y Buckley, 1988). Cuarta, densificación. LSA aplica SVD a la matriz TF-IDF y deja cada documento en 3 factores latentes (Deerwester et al., 1990). En paralelo, una matriz de coocurrencia con ventana 2 se convierte a PPMI y se reduce con SVD: es la familia count-based emparentada con GloVe (Pennington et al., 2014). El vector de un documento es la media de los embeddings de sus palabras. Quinta, comparación con similitud coseno, invariante a la norma del vector y estándar en recuperación de información.

La diferencia conceptual es clave para la rúbrica. Un one-hot de “apartamento en Bogotá” y “inmueble en la capital” puede ser ortogonal si no comparten tokens. Un embedding denso busca un eje de “vivienda” donde ambos se proyectan cerca. Word2Vec y BERT siguen esa idea con redes; aquí se usa álgebra lineal reproducible, sin claves de API, para que el profesor clone el repo y obtenga las mismas figuras.

### **3. Diseño experimental**


Se usaron 8 documentos etiquetados por tema. El bloque NLP repite embeddings, lenguaje y natural; el de vivienda, apartamento, Bogotá, habitaciones y precio; el de deporte, equipo, fútbol y partido. Esa repetición controlada permite medir coseno intra-tema (pares del mismo tema) frente a inter-tema (pares de temas distintos). La consulta de prueba fue: «Necesito un apartamento de tres habitaciones con parqueadero en Bogotá». Se proyectó con el mismo vectorizador TF-IDF y el mismo SVD de LSA, y se ordenó el corpus por coseno. Semilla 42 en PCA y SVD.

#### 4. Resultados (salida de Colab)

La Tabla 1 copia la celda 7 del notebook. Al pasar de 57 dimensiones dispersas a 3 densas, el coseno intra-tema pasa de 0.24–0.35 a  $\approx 0.99$ , y el inter-tema sigue cerca de 0. En TF-IDF, D4 y D5 (vivienda) se parecen 0.40 y D4 vs D7 (deporte) queda en 0.00: sin palabras compartidas no hay señal. LSA no inventa temas; comprime las correlaciones de TF-IDF. La varianza de los tres componentes LSA es 0.1317, 0.1303 y 0.1630 (suma 0.425): basta para separar tres tópicos, no para reconstruir el vocabulario completo.

| Representación | Dim. | Coseno intra-tema | Coseno inter-tema |
|----------------|------|-------------------|-------------------|
| one-hot        | 57   | 0.3460            | 0.0053            |
| TF-IDF         | 57   | 0.2363            | 0.0045            |
| LSA            | 3    | 0.9879            | 0.0155            |
| PPMI+SVD       | 3    | 0.9872            | 0.0351            |

Tabla 1. Separación por tema medida en el notebook ejecutado en Colab. Elaboración a partir de la celda 7.



*Figura 1. Similitud coseno TF-IDF. Salida de Google Colab (celda 8).*

En la Figura 1 se ven tres bloques: D1–D3 (NLP, cosenos 0.17–0.19), D4–D6 (vivienda; el par D4–D5 llega a 0.40) y D7–D8 (deporte, 0.30). Entre NLP y el resto el mapa es amarillo (0.00). Es exactamente el límite de una representación léxica: si no hay tokens en común, el ángulo es 90°.




Figura 2. Similitud coseno LSA (3 dimensiones). Salida de Google Colab (celda 8).

La Figura 2 es el mismo corpus en el espacio denso. Los bloques intra-tema pasan a azul oscuro ( $\approx 1.00$ ) y el cruce entre temas permanece claro. D1, D2 y D3 quedan casi indistinguibles entre sí; D4, D5 y D6 forman el otro cubo; D7 y D8 el tercero. Ahí se ve el oficio del embedding: documentos que en TF-IDF apenas se rozaban ahora comparten un factor latente de tema.




Figura 3. PCA de documentos sobre embeddings LSA. Salida de Google Colab (celda 9).

La Figura 3 proyecta esos vectores a 2D. Azul (NLP: D1–D3) se agrupa abajo a la izquierda; rojo (vivienda: D4 y D5 casi superpuestos, D6 un poco desplazado) a la derecha; verde (deporte: D7–D8) arriba. El eje X separa vivienda del resto; el eje Y separa deporte. No es un t-SNE industrial: ocho puntos, tres temas, separación legible.




Figura 4. PCA sobre la media PPMI+SVD. Salida de Google Colab (celda 9).

La Figura 4, construida con coocurrencia local y no con TF-IDF, reproduce las mismas tres nubes. El embedding de documento como promedio de palabras hereda la estructura de contexto: “apartamento” y “habitaciones” empujan hacia vivienda; “fútbol” y “partido” hacia deporte.

La Tabla 2 es el ranking de la consulta «Necesito un apartamento de tres habitaciones con parqueadero en Bogotá», proyectada con el mismo TF-IDF+SVD (celda 10). Los tres avisos de vivienda salen primero (0.9998, 0.9997 y 0.9656). El resto del corpus queda en torno a cero. D6 no menciona parqueadero y aun así entra al bloque: eso no lo haría un filtro booleano.

| Puesto | Id | Tema     | Coseno LSA |
|--------|----|----------|------------|
| 1      | D5 | Vivienda | 0.9998     |
| 2      | D4 | Vivienda | 0.9997     |
| 3      | D6 | Vivienda | 0.9656     |
| 4      | D7 | Deporte  | 0.0219     |
| 5      | D3 | NLP      | 0.0000     |
| 6      | D2 | NLP      | 0.0000     |



|   |    |         |         |
|---|----|---------|---------|
| 7 | D1 | NLP     | 0.0000  |
| 8 | D8 | Deporte | -0.0553 |

Tabla 2. Recuperación semántica de la consulta de vivienda. Salida de Colab, celda 10.

## 5. Análisis y límites

Tres lecturas. Una, el cuello de botella del NLP clásico no es “pasar texto a números”, sino elegir una geometría que no colapse la semántica. Dos oraciones sin solapamiento léxico son invisibles para TF-IDF y visibles para LSA si pertenecen al mismo factor. Dos, la dimensionalidad no es un lujo: 57 ejes one-hot vs 3 densos. En un corpus real el vocabulario llega a decenas de miles; los embeddings (Word2Vec 300-D, BERT 768-D) son la misma apuesta a mayor escala (Mikolov et al., 2013; Devlin et al., 2019). Tres, el laboratorio es deliberadamente pequeño. Un modelo contextual distinguiría “banco” (finanzas) de “banco” (asiento); LSA sobre ocho oraciones no. El valor académico está en dejar el pipeline transparente y medido, no en competir con un API comercial.

## 6. Conclusiones

Se transformó texto en embeddings siguiendo un proceso explícito: limpieza, vectores dispersos, reducción densa, coseno y consulta. Los números del laboratorio —sobre todo LSA intra 0.99 frente a inter 0.02, y un ranking de consulta que recupera los tres avisos de vivienda— muestran que el espacio vectorial organizó el significado. El código modular está en GitHub y se puede reejecutar en Colab. Esa es la evidencia que pide la rúbrica: comprensión técnica, notebook funcional y análisis de resultados, no una captura aislada.

## Referencias

- Deerwester, S., Dumais, S. T., Furnas, G. W., Landauer, T. K., y Harshman, R. (1990). Indexing by latent semantic analysis. *Journal of the American Society for Information Science*, 41(6), 391–407.
- Devlin, J., Chang, M.-W., Lee, K., y Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. En *Proceedings of NAACL-HLT 2019* (pp. 4171–4186).
- Jurafsky, D., y Martin, J. H. (2023). *Speech and language processing* (3.<sup>a</sup> ed. en borrador). <https://web.stanford.edu/~jurafsky/slp3/>
- Mikolov, T., Chen, K., Corrado, G., y Dean, J. (2013). Efficient estimation of word representations in vector space. <https://arxiv.org/abs/1301.3781>
- Pennington, J., Socher, R., y Manning, C. D. (2014). GloVe: Global vectors for word representation. En *Proceedings of EMNLP 2014* (pp. 1532–1543).
- Salton, G., y Buckley, C. (1988). Term-weighting approaches in automatic text retrieval. *Information Processing & Management*, 24(5), 513–523.