

Informe: Procesamiento de texto

PROCESAMIENTO DE LENGUAJE NATURAL

WILSON ALFONSO DÍAZ CAPADOR

UNIVERSIDAD DE CUNDINAMARCA

PROGRAMA ESPECIALIZACIÓN EN INTELIGENCIA ARTIFICIAL

FACULTAD DE INGENIERÍA

2026

Procesamiento de texto: laboratorio de la cadena clásica al modelo de lenguaje

Enlaces de evidencia

Repositorio público: <https://github.com/SonicWD/PROCESAMIENTO-DE-LENGUAJE-NATURAL>.
 Notebook del laboratorio: https://colab.research.google.com/github/SonicWD/PROCESAMIENTO-DE-LENGUAJE-NATURAL/blob/main/REA1_Procesamiento_Texto/Laboratorio_Procesamiento_Texto.ipynb.

La semilla de los sorteos y del clasificador es 42. El etiquetado, la lematización, el análisis de dependencias y el reconocimiento de entidades usan el modelo `es_core_news_sm` de spaCy. La traducción usa Opus-MT español–inglés ejecutado con CTranslate2. La generación con modelo de lenguaje grande usa Qwen2.5-0.5B-Instruct en CPU, con decodificación greedy (`do_sample = falso`) para que la salida no dependa de un muestreo aleatorio.

Introducción

Procesar texto es convertir una cadena de caracteres en una representación sobre la que se puede contar, clasificar, comparar o generar. El recorrido no es una lista de herramientas sueltas: cada paso deshace una ambigüedad distinta. La normalización decide qué variaciones de forma son la misma palabra; las stopwords deciden qué palabras no aportan tema; stemming y lematización reducen la flexión con criterios distintos; la frecuencia y el IDF convierten el documento en un vector; el etiquetado, el parsing y las entidades recuperan estructura que la bolsa de palabras tira. Encima de esa base, el laboratorio compara métodos clásicos y neuronales en las tareas que el enunciado pide juntas: similitud, clasificación, minería, resumen, pregunta-respuesta, traducción y generación, esta última tanto con un modelo de n-gramas como con un modelo de lenguaje grande (Jurafsky y Martin, 2023; Manning et al., 2008).

El corpus de trabajo tiene 18 oraciones en español, repartidas en tecnología, salud y deporte. Quince repiten a propósito el léxico de su clase (modelo y texto; paciente y médico; equipo y partido). Las tres últimas mezclan clases. Ese diseño permite ver cuándo un método acierta porque hay solapamiento léxico y cuándo se rompe en cuanto el texto deja de ser puro. Un párrafo aparte, sobre un convenio de la Universidad de Cundinamarca, sirve para entidades, parsing, resumen y preguntas, porque ahí hay nombres, lugares y fechas que una oración suelta no contiene.

Normalización y stopwords

La normalización de este laboratorio pasa el texto a minúsculas, elimina URL y puntuación, conserva tildes y ñe, y colapsa los espacios. No quita acentos: el etiquetador y el lematizador en español dependen de ellos, y borrarlos antes de tiempo junta palabras que no son la misma (sí / si). Sobre la cadena sucia «¡El Modelo de Lenguaje, en la Universidad de Cundinamarca, procesa TEXTO!!! Visite <https://ejemplo.edu/nlp>» el resultado es «el modelo de lenguaje en la universidad de cundinamarca procesa texto visite». La URL desaparece, las mayúsculas de TEXTO se unifican y los signos de exclamación no ocupan un token.

De esos 12 tokens de contenido potencial, las stopwords del español (NLTK, más una lista corta de ruido) dejan 7: modelo, lenguaje, universidad, cundinamarca, procesa, texto, visite. Artículos y preposiciones se van porque en una bolsa de palabras aparecen en casi todos los documentos y no separan temas (Manning et al., 2008). El laboratorio no las borra antes del análisis sintáctico: «en» marca el oblicuo de Bogotá, y quitarla rompería el árbol. La limpieza léxica y el análisis lingüístico no comparten la misma entrada.

Stemming y lematización

Stemming y lematización persiguen lo mismo —una forma canónica— con evidencia distinta. El stemmer de Snowball para español corta sufijos por reglas y no consulta un diccionario; por eso la raíz puede no ser una palabra (Porter, 2001). El lema de spaCy sí apunta a la entrada de diccionario y usa el contexto de la oración (Honnibal et al., 2020). La Tabla 1 compara ambos sobre «Los modelos de lenguaje procesan documentos clínicos y generan resúmenes.».

Tabla 1

Stem de Snowball y lema de spaCy para la misma oración

Token	Stem	Lema
Los	los	el
modelos	model	modelo
procesan	proces	procesar
documentos	document	documento
clínicos	clínic	clínico
generan	gener	generar
resúmenes	resumen	resumen

«modelos» ilustra el contraste: el stem es «model», que no es español, y el lema es «modelo», que sí lo es. «procesan» y «generan» caen a «proces» y «gener» por corte de sufijo, mientras el lema recupera el infinitivo (procesar, generar). «Los» se lematiza como «el»: el lematizador reconoce el artículo y el stemmer no tiene por qué. En recuperación de información el stemmer barato agrupa más formas y también más falsos amigos; el lema es preferible cuando la salida se va a leer o cuando el idioma tiene flexión irregular. Aquí se usan los dos, cada uno en su sitio: Snowball para mostrar la reducción ciega, y el lema dentro de la tabla morfosintáctica.

Term frequency e inverse document frequency

La frecuencia de término (TF) cuenta cuántas veces aparece un token en el corpus ya normalizado y sin stopwords. No es una medida de importancia: un término repetido por diseño del corpus sube aunque sea obvio. En la Figura 1 los primeros puestos son partido (7), paciente (7), modelo (7), equipo (6), texto (6), lenguaje (5), médico (4), hospital (4). Partido, paciente y

modelo empatan arriba porque cada clase fue escrita para repetir su palabra ancla. Esa repetición es el control del experimento, no un hallazgo del mundo.




Figura 1

Frecuencia de los doce términos más repetidos en el corpus limpio

El IDF corrige esa obviedad. Con el suavizado de scikit-learn, $\text{idf}(t) = \ln((1+n)/(1+\text{df}(t)))+1$, donde $\text{df}(t)$ es el número de documentos que contienen t y n es el tamaño del corpus (Pedregosa et al., 2011; Salton y Buckley, 1988). Un término que está en casi todos los documentos pesa poco; uno que está en pocos pesa más. «modelo» aparece en 7 documentos y queda con IDF 1.865. «gol» aparece en 2 y sube a 2.846. La Figura 2 ordena ese contraste. El producto TF-IDF, que alimenta la similitud y el clasificador, premia la palabra que es frecuente en un documento y rara en el resto.




Figura 2

IDF suavizado de términos de clase. El término menos compartido pesa más

Etiquetado morfosintáctico y parsing

La bolsa de palabras no sabe quién hizo qué. El etiquetado de parte de la oración (POS) asigna a cada token una categoría, y el parsing de dependencias dice de qué palabra cuelga. Sobre «Ana Rojas presentó el convenio en Bogotá.» spaCy marca «presentó» como verbo y raíz, «Ana Rojas» como sujeto (nsubj, con Rojas en aposición plana), «convenio» como objeto y «Bogotá» como oblicuo introducido por «en» (Tabla 2). Esa estructura es la que después usa la pregunta «¿en qué ciudad se presentó el convenio?»: la ciudad del evento es el oblicuo del verbo, no el primer lugar que aparezca en el párrafo.

Tabla 2

Análisis morfosintáctico y de dependencias de la oración de prueba

Token	POS	Dependencia	Cabeza
Ana	PROPN	nsubj	presentó
Rojas	PROPN	flat	Ana
presentó	VERB	ROOT	presentó
el	DET	det	convenio

convenio	NOUN	obj	presentó
en	ADP	case	Bogotá
Bogotá	PROPN	obl	presentó
.	PUNCT	punct	presentó

En el párrafo largo la distribución de categorías es ADP 15, NOUN 15, PROPN 13, DET 12, VERB 8, ADJ 6. Predominan adposiciones, sustantivos y nombres propios, coherente con un texto que localiza instituciones y personas. La Figura 3 resume ese conteo. El límite del modelo pequeño es de cobertura, no de formato: las etiquetas salen siempre, pero un nombre poco frecuente puede recibir la categoría equivocada, como se ve en las entidades.




Figura 3

Distribución de categorías gramaticales en el párrafo del convenio

Entidades nombradas

El reconocedor del mismo modelo devuelve persona (PER), lugar (LOC), organización (ORG) y miscelánea (MISC). La Tabla 3 lista lo que marcó en el párrafo del convenio. Ana Rojas y la segunda mención «Rojas» salen como persona; la Universidad de Cundinamarca,

como organización; Fusagasugá y Bogotá, como lugar. Hasta ahí el sistema hace el trabajo que se le pide.

Tabla 3

Entidades detectadas por es_core_news_sm en el párrafo del convenio

Texto	Etiqueta
Ana Rojas	PER
Universidad de Cundinamarca	ORG
Fusagasugá	LOC
Bogotá	LOC
Ministerio de Tecnologías	LOC
El proyecto Andina-NLP	MISC
El hospital San Rafael	MISC
Rojas	PER
La gobernación de Cundinamarca	MISC

Los errores importan más que los aciertos, porque muestran qué no se puede dar por hecho con un modelo pequeño. «Ministerio de Tecnologías» queda como lugar y no como organización. «El hospital San Rafael» y «La gobernación de Cundinamarca» entran como MISC y se comen el artículo inicial: el span está mal delimitado. «El proyecto Andina-NLP» también cae en MISC. Un modelo más grande, o un gazetteer del dominio, corregiría parte de eso; el laboratorio lo deja visible para no presentar el NER como una lista limpia. La pregunta sobre el hospital no confía en esa etiqueta: busca el patrón «hospital» más el nombre propio que sigue.

Similitud de oraciones

La similitud entre oraciones se mide con el coseno de sus vectores TF-IDF, contruidos sin stopwords. El coseno vale 1 si los vectores apuntan al mismo sitio y 0 si no comparten términos (Manning et al., 2008). No mide paráfrasis: dos oraciones del mismo tema con palabras distintas pueden dar cero, y por eso este número no sustituye a un embedding. Mide solapamiento ponderado, que es exactamente lo que el corpus controla.

La media intra-clase es 0.394 y la inter-clase es 0.0. El cero entre clases no es un redondeo amable: una vez quitadas las stopwords, las oraciones de tecnología, salud y deporte de la muestra no comparten tokens de contenido. Dentro de la clase el coseno queda en torno a 0,39 porque comparten el ancla (modelo, paciente, equipo) y no la oración entera. La Figura 4 es el mapa: bloques en la diagonal y ceros fuera. Si el informe anterior de embeddings buscaba acercar textos sin palabras en común, este mapa muestra el techo del método léxico.




Figura 4

Coseno TF-IDF entre seis oraciones, dos por clase

Clasificación de texto

El clasificador es una regresión logística sobre TF-IDF, evaluada dejando uno fuera: cada oración se predice con un modelo entrenado en las otras diecisiete. La exactitud es 0.833 y el F1

macro es 0.833. Quince oraciones, las de léxico puro, se clasifican bien. Fallan las tres mezclas, y fallan siempre hacia la clase cuyo léxico domina la oración, no hacia la etiqueta que se les puso (Tabla 4). La Figura 5 es la matriz: la diagonal concentra los aciertos y los tres errores salen de la diagonal.

Tabla 4

Oraciones mezcladas y clase que el modelo les asigna

Oración	Etiqueta	Predicción
El médico revisó al paciente en el hospital y consultó un modelo.	tecnología	salud
El equipo de fútbol ganó el partido y luego el paciente celebró.	salud	deporte
El modelo de lenguaje procesa el texto del partido final.	deporte	tecnología




Figura 5

Matriz de confusión con validación dejando uno fuera

Los pesos confirman que el modelo no «entiende» el tema: se apoya en las palabras ancla. En deporte pesan partido (0.726), equipo (0.57), final (0.457), gol (0.388); en salud, paciente (0.626), infección (0.363), médico (0.307), hospital (0.307); en tecnología, modelo (0.614), texto (0.469), lenguaje (0.369). Por eso «El modelo de lenguaje procesa el texto del partido final», etiquetada como deporte, cae en tecnología: modelo, lenguaje y texto suman más que partido. El experimento es pequeño a propósito. Con 18 oraciones un hapax puede recibir peso, y la exactitud no se extrapola a un corpus abierto. Lo que sí se extrapola es el mecanismo: una bolsa de palabras clasifica el vocabulario dominante.

Minería de texto

La minería, en este laboratorio, no es un octavo algoritmo con otro nombre: es la lectura conjunta de frecuencias, bigramas y riqueza léxica para describir el corpus antes de modelar (Feldman y Sanger, 2007). La relación tipo/token (TTR) mide cuánta repetición hay. Un TTR cercano a 1 significa que casi cada token es nuevo; uno más bajo significa que el texto recicla formas.

Tabla 5

Riqueza léxica y bigrama más frecuente por clase

Clase	Tokens	Tipos	TTR	Bigrama principal
tecnología	36	23	0.639	modelo lenguaje
salud	34	24	0.706	paciente infección
deporte	31	18	0.581	partido final

El bigrama principal de tecnología es «modelo lenguaje», el de las otras clases gira en torno a su ancla (paciente, equipo, partido). Esa colocación es el mismo fenómeno que el TF, visto de a dos palabras: el corpus fue escrito para que la clase tuviera una frase recurrente. En un corpus periodístico el bigrama serviría para descubrir el tema; aquí sirve para verificar que el

diseño experimental quedó escrito en los datos. La minería útil, en ambos casos, es la que se puede señalar en una tabla y no una nube de palabras sin conteo.

Resumen extractivo y resumen con modelo de lenguaje

El resumen extractivo usa TextRank: cada oración es un nodo, la arista es el coseno TF-IDF y el puntaje se itera con amortiguación 0,85, el mismo esquema de PageRank aplicado a texto (Mihalcea y Tarau, 2004). Se conservan las dos oraciones de mayor puntaje, en su orden original. Los puntajes son 0.29 para la oración 1; 0.03 para la oración 2; 0.03 para la oración 3; 0.14 para la oración 4; 0.17 para la oración 5. Entran la primera, que presenta a Ana Rojas y el convenio, y la última, que fija el financiamiento hasta diciembre de 2026. Quedan fuera el hospital San Rafael y el nombre del proyecto. TextRank no sabe que esos datos son importantes: sabe qué oración se parece más a las otras. La primera comparte instituciones y lugares con el resto del párrafo; la del hospital es corta y casi aislada, y por eso su puntaje se hunde.

El resumen abstractivo se pidió al modelo Qwen/Qwen2.5-0.5B-Instruct en una sola oración. La salida quedó cortada por el tope de tokens, a mitad de «Cundinamarca»: «Ana Rojas, investigadora de la Universidad de Cundinamarca en Fusagasugá, presentó un convenio con el Ministerio de Tecnologías para desarrollar un proyecto llamado "Andina-NLP" que entrenará modelos en español para resumir historias clínicas, mientras que el Hospital San Rafael aportaría el corpus anonimizado. Rojas explicó que el modelo no reemplazara al médico, sino que solo ordenaba el texto para que la revisión humana fuera más rápida, y la gobernación de Cundin». A diferencia de TextRank, menciona el proyecto y el corpus, es decir, comprime en vez de copiar. El costo es el habitual de un modelo de 0,5 mil millones de parámetros sin ajuste al dominio: puede alargar la frase, cambiar un tiempo verbal o no cerrar la oración si el tope de tokens la

corta. Para un informe clínico esa diferencia no es de estilo. El extractivo no inventa, y se le puede citar la oración fuente; el abstractivo es más legible y hay que verificarlo contra el párrafo.

Question answering

La pregunta-respuesta clásica del laboratorio es extractiva y de dos pasos, el esquema de recuperación más lectura que describe Jurafsky y Martin (2023). Primero se elige la oración del párrafo con mayor coseno TF-IDF respecto de la pregunta. Después se recorta un tramo según el tipo: la persona, el lugar oblicuo del verbo, el nombre que sigue a «hospital», o una fecha con mes y año. Sobre cuatro preguntas el recorte contiene la respuesta esperada en 4 de 4 casos (Tabla 6).

Tabla 6

Preguntas, oración recuperada y tramo extraído

Pregunta	Respuesta	Coseno
¿Quién presentó el convenio en Bogotá?	Ana Rojas	0.3608
¿En qué ciudad se presentó el convenio?	Bogotá	0.2686
¿Qué hospital aportará el corpus?	San Rafael	0.6341
¿Hasta cuándo financiará la gobernación la primera fase?	diciembre de 2026	0.6704

La pregunta de la ciudad es el caso que justifica el parsing. La oración recuperada contiene Fusagasugá y Bogotá. Quedarse con el primer lugar habría respondido Fusagasugá, que es la sede de la investigadora y no el sitio de la presentación. El oblicuo de «presentó» es Bogotá, y esa es la respuesta. El hospital no sale de la etiqueta NER —el modelo lo marcó mal— sino de la expresión regular sobre la oración ya elegida. Las dos piezas se necesitan: la similitud encuentra el sitio del párrafo y la regla encuentra el dato.

El mismo párrafo se le pasó al modelo de lenguaje, pidiéndole solo el dato. Acertó el texto esperado en 4 de 4 preguntas, pero la forma de la respuesta no es un tramo: a veces devuelve la frase completa («Ana Rojas presentó el convenio en Bogotá») en lugar del nombre.

Para una rúbrica automática de coincidencia exacta eso baja el puntaje aunque la información esté. El sistema clásico devuelve un span corto y citable; el modelo grande devuelve una paráfrasis que hay que volver a leer.

Traducción

La traducción es el modelo bilingüe Opus-MT español–inglés de Tiedemann y Thottingal (2020), empaquetado para CTranslate2 y decodificado con haz de tamaño 5. No llama a un servicio externo: el mismo archivo produce la misma salida. La Tabla 7 muestra tres oraciones del dominio del laboratorio.

Tabla 7

Traducción es→en con Opus-MT

Español	Inglés
El modelo de lenguaje resume historias clínicas.	The language model summarizes clinical stories.
El hospital San Rafael aportará un corpus anonimizado.	The San Rafael hospital will provide an anonymous corpus.
La selección de fútbol entrenó en Bogotá.	The football team trained in Bogotá.

«historias clínicas» sale como clinical stories, no como clinical records. El modelo eligió el sentido cotidiano de historia y no el sentido de historia clínica. «anonimizado» queda en anonymous, cercano pero no el participio técnico anonymized. «Bogotá» se parte en subpalabras y se reconstruye como Bogotá, con una ese de más: el error está en la segmentación BPE de un nombre con tilde, no en la gramática de la oración, que sí produjo trained. Son tres fallos pequeños y los tres son del tipo que un revisor humano ve enseguida y una métrica de corpus grande promedia. En un texto con topónimos y léxico de salud, el sistema sirve como borrador y no como versión final.

Generación estadística y generación con modelo de lenguaje

La generación estadística es un modelo de trigramas con retroceso: si el par de palabras no se vio, se usa el bigrama; si tampoco, el unigrama. Es el modelo de lenguaje de conteos de

Jurafsky y Martin (2023), sin red neuronal. Entrenado solo con las oraciones puras de cada clase y arrancado con el par ancla, produjo: tecnología, «modelo lenguaje predice palabra texto técnico clasifica documentos red neuronal entrena modelo»; salud, «paciente médico indicó tratamiento paciente infección respiratoria médico indicó tratamiento paciente infección»; deporte, «equipo fútbol partido final entrenador cambió táctica equipo partido final entrenador cambió». Salud y deporte entran en bucle (tratamiento... infección... tratamiento; partido final... entrenador...). Con tan pocos trigramas distintos, la cadena más probable es repetir el único camino visto. El texto se mantiene en el tema y no es una oración: no hay concordancia ni puntuación porque el modelo no las modela, solo predice el token siguiente.

La generación con modelo de lenguaje grande usa Qwen/Qwen2.5-0.5B-Instruct, un modelo instructivo de medio millar de millones de parámetros (Qwen Team, 2024). El prompt pidió exactamente dos oraciones en español sobre un modelo que resume historias clínicas en un hospital. La salida fue: «1. El modelo de lenguaje ha sido diseñado para proporcionar una descripción precisa y detallada de las historias clínicas presentadas por los pacientes en el hospital, facilitando la atención médica y ayudándonos a entender mejor cómo se desarrollan y evolucionan estas enfermedades.

2. Este modelo de lenguaje permite al personal médico del hospital recopilar información precisa y relevante sobre las historias clínicas, lo cual es crucial para garantizar que cada paciente tenga acceso a un tratamiento adecuado y eficaz. Además, ayuda a mejorar la calidad de vida de los pacientes y reducir el tiempo que tarda en llegar a un diagnóstico final.». A diferencia del trigramas, hay oraciones, hay concordancia y el contenido sigue el pedido. También se nota el tamaño: numera las oraciones aunque se le pidió no hacer una lista, y se extiende más de lo

necesario. No sustituye a un modelo de varios miles de millones de parámetros, y no hace falta fingir que lo hace. Lo que el laboratorio muestra es la diferencia de familia. El trigramma solo puede recombinar el corpus; el modelo preentrenado puede formular una idea que no estaba escrita en esas dieciocho oraciones, con los errores de instrucción propios de un modelo chico en CPU.

Discusión

Leídos juntos, los diecisiete procedimientos se separan en dos familias. La primera cuenta y corta: normalización, stopwords, stems, TF, IDF, similitud, clasificación, minería, TextRank, trigramas y la recuperación de la pregunta. Todo eso es determinista, cabe en CPU sin descargar miles de millones de pesos, y falla de un modo que se puede señalar: la clase mezclada se va con el léxico mayoritario, el resumen extractivo deja fuera el hospital porque su oración no se parece a las demás, el trigramma entra en bucle. La segunda familia predice: lema y árbol con una red pequeña, entidades, Opus-MT y Qwen. Acierta más en la forma lingüística y puede decir algo que no está copiado del corpus, y el error cambia de naturaleza: una etiqueta LOC donde iba ORG, un topónimo con una ese de más, un resumen que hay que contrastar con la fuente.

El diseño del corpus es a la vez la fortaleza y el límite. Repetir «modelo», «paciente» y «equipo» hace visibles el IDF, el mapa de cosenos y los pesos del clasificador. También impide tratar el 0,83 de exactitud como un resultado sobre español en general. Un corpus de noticias mezclaría los temas en la misma oración sin haberlo pedido, y el cero inter-clase de la Figura 4 desaparecería. El párrafo del convenio, en cambio, no está plantillado: por eso el NER se equivoca en el ministerio y en el hospital, y por eso esa parte del informe pesa más que la tabla de frecuencias.

Conclusiones

El laboratorio recorre la cadena pedida sobre un corpus propio en español y deja cada salida contrastada con lo que el método puede y no puede ver. Normalizar no es lematizar: Snowball produce «model» y spaCy produce «modelo». Contar no es pesar: partido, paciente y modelo lideran el TF porque se repitieron, y el IDF sube precisamente en el término que está en menos documentos. La similitud intra-clase (0.394) se separa de la inter-clase (0.0) solo después de quitar stopwords. El clasificador acierta el léxico puro y falla, de manera sistemática, en las tres oraciones mezcladas (exactitud 0.833). TextRank cita dos oraciones y se deja el hospital afuera; el modelo de lenguaje comprime más hechos y hay que verificarlo. Opus-MT traduce la estructura y tropieza con el sentido clínico y con Bogotá. El trigramma permanece en el tema y entra en bucle; Qwen2.5-0.5B escribe oraciones nuevas y no obedece el formato al pie de la letra. Esa es la evidencia del laboratorio: no una lista de técnicas marcadas, sino el punto en el que cada una deja de ser fiable.

Referencias

- Feldman, R., y Sanger, J. (2007). The text mining handbook: Advanced approaches in analyzing unstructured data. Cambridge University Press.
- Honnibal, M., Montani, I., Van Landeghem, S., y Boyd, A. (2020). spaCy: Industrial-strength natural language processing in Python. <https://doi.org/10.5281/zenodo.1212303>
- Jurafsky, D., y Martin, J. H. (2023). Speech and language processing (3.^a ed., borrador). <https://web.stanford.edu/~jurafsky/slp3/>
- Manning, C. D., Raghavan, P., y Schütze, H. (2008). Introduction to information retrieval. Cambridge University Press.
- Mihalcea, R., y Tarau, P. (2004). TextRank: Bringing order into text. En Proceedings of EMNLP 2004 (pp. 404–411).
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., y Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- Porter, M. F. (2001). Snowball: A language for stemming algorithms. <http://snowball.tartarus.org/texts/introduction.html>
- Qwen Team. (2024). Qwen2.5 technical report. <https://arxiv.org/abs/2412.15115>
- Salton, G., y Buckley, C. (1988). Term-weighting approaches in automatic text retrieval. *Information Processing & Management*, 24(5), 513–523. [https://doi.org/10.1016/0306-4573\(88\)90021-0](https://doi.org/10.1016/0306-4573(88)90021-0)

Tiedemann, J., y Thottingal, S. (2020). OPUS-MT: Building open translation services for the world. En Proceedings of the 22nd Annual Conference of the European Association for Machine Translation (pp. 117–120).